

Deteksi Ketidaksesuaian Judul dan Isi Berita Berbahasa Indonesia Menggunakan Fitur Leksikal Semantik dan Ensemble Gradient Boosting

1st Nayla Aqila Argia
Program Studi Teknologi Rekayasa
Perangkat Lunak
Institut Pertanian Bogor
Bogor, Indonesia
naylaargia@apps.ipb.ac.id

2nd Alif Muslim Abdurrahman
Program Studi Sistem Informasi
Universitas Telkom Bandung
Bandung, Indonesia
alifmuslim@student.telkomuniversity.a
c.id

3rd Ezra Faira Azzahra Faisal
Program Studi Teknologi Rekayasa
Perangkat Lunak
Institut Pertanian Bogor
Bogor, Indonesia
faira_ezra@apps.ipb.ac.id

Abstrak

Perkembangan media digital di Indonesia mendorong maraknya praktik *clickbait*, yaitu judul berita yang sengaja dibuat menyesatkan untuk menarik perhatian pembaca. Fenomena ini menimbulkan kebutuhan akan sistem deteksi otomatis yang mampu mengidentifikasi kesesuaian antara judul dan isi berita. Penelitian ini mengembangkan sistem klasifikasi biner menggunakan dataset kompetisi Data Analysis Competition IFEST Unpad 2026 yang terdiri dari 14.394 data latih dengan distribusi kelas yang tidak seimbang, yaitu 90,04% label Sesuai dan 9,96% label Tidak Sesuai. Sistem menggabungkan fitur leksikal berupa TF-IDF, BM25, dan Jaccard Similarity dengan fitur semantik dari FastText yang dilatih dari awal. Model klasifikasi menggunakan ensemble LightGBM dan XGBoost dengan optimasi hyperparameter melalui Optuna serta evaluasi menggunakan 5-Fold Stratified Cross Validation. Hasil pengujian pada *leaderboard* Kaggle menunjukkan Macro F1-Score sebesar 0,58957, sedangkan evaluasi internal pada data Out-of-Fold menghasilkan Macro F1-Score 0,5723 pada threshold optimal 0,47 dengan akurasi 82%. Ketidakseimbangan kelas menjadi faktor utama yang membatasi performa model pada kelas minoritas.

Keywords— *klasifikasi teks, kesesuaian judul-isi, LightGBM, XGBoost, TF-IDF, BM25, FastText, data tidak seimbang*

I. PENDAHULUAN

Perpindahan media berita dari fisik ke digital mempermudah akses informasi bagi masyarakat, namun kemudahan ini turut mendorong maraknya praktik *clickbait* pada media daring Indonesia, yaitu judul yang dibuat menyesatkan dan melebih-lebihkan demi menarik perhatian pembaca. Risiko ini semakin besar mengingat minat baca masyarakat Indonesia yang masih tergolong rendah, sehingga pembaca yang hanya membaca judul tanpa menelaah isi berita secara keseluruhan rentan menerima informasi yang keliru [1]. Solihin dkk. [2] menjelaskan bahwa salah satu permasalahan utama *clickbait* berkaitan dengan ketidaksesuaian antara judul dan isi berita.

Urgensi permasalahan ini terletak pada besarnya skala dan dampaknya terhadap kualitas informasi publik. Volume berita daring di Indonesia terus bertambah setiap hari, sehingga verifikasi manual oleh redaksi terhadap kesesuaian setiap judul dengan isinya menjadi tidak lagi mungkin dilakukan secara konsisten. Di sisi lain, ketidaksesuaian judul-isi berkontribusi pada penyebaran misinformasi dan menurunkan kualitas literasi media

masyarakat, khususnya bagi pembaca yang hanya membaca judul tanpa menelaah isi berita secara utuh [1]. Kebutuhan akan solusi deteksi otomatis semakin mendesak mengingat pendekatan berbasis model besar seperti pretrained transformer atau *LLM* tidak selalu dapat digunakan secara bebas, baik karena keterbatasan sumber daya komputasi maupun batasan tertentu dalam konteks penerapan, sehingga diperlukan pendekatan yang tetap akurat namun efisien. Selain itu, media daring dan platform agregator berita membutuhkan alat bantu penyaringan awal yang dapat memprioritaskan berita berisiko tinggi untuk ditinjau editor secara manual, alih-alih memverifikasi seluruh artikel satu per satu.

Berangkat dari permasalahan tersebut, penelitian ini bertujuan untuk mengembangkan sebuah sistem deteksi otomatis yang mampu mengidentifikasi kesesuaian antara judul dengan isi berita berbahasa Indonesia, guna membantu menekan proliferasi berita yang semata-mata dibuat untuk menarik perhatian atau bahkan sengaja menyesatkan pembaca. Secara lebih rinci, penelitian ini bertujuan merancang dan menguji kombinasi fitur leksikal (TF-IDF, BM25, Jaccard Similarity) dan fitur semantik (FastText embedding) untuk menangkap kemiripan judul dan isi berita baik dari sisi kata maupun makna, membangun model ensemble gradient boosting (LightGBM dan XGBoost) yang efisien secara komputasi serta mampu menangani data berdimensi tinggi dan tidak seimbang, mengevaluasi performa model menggunakan Macro F1-Score agar kemampuan model dalam mengenali kelas minoritas tetap terukur secara adil, serta memberikan rekomendasi penerapan praktis sistem sebagai alat bantu penyaringan awal bagi redaksi media daring atau platform agregator berita..

II. KAJIAN PUSTAKA

Bagian ini menjelaskan landasan teori dan konsep-konsep yang digunakan dalam penelitian, meliputi teknik representasi teks, algoritma klasifikasi, serta metode optimasi hyperparameter yang diterapkan.

A. Term Frequency-Inverse Document Frequency (TF-IDF)

TF-IDF merupakan teknik pembobotan teks yang mengukur pentingnya suatu kata dalam dokumen relatif terhadap keseluruhan corpus [3]. TF menghitung frekuensi kemunculan kata dalam dokumen, sedangkan IDF menghitung

kelangkaan kata tersebut di seluruh corpus. Rumus TF-IDF dinyatakan sebagai berikut:

$$\text{TF-IDF}(t, d) = \text{TF}(t, d) \times \log\left(\frac{N}{\text{DF}(t)}\right)$$

Di mana $\text{TF}(t, d)$ adalah frekuensi term t dalam dokumen d , N adalah jumlah total dokumen, dan $\text{DF}(t)$ adalah jumlah dokumen yang mengandung term t .

B. Best Matching 25 (BM25)

BM25 merupakan fungsi ranking probabilistik yang banyak digunakan dalam sistem information retrieval untuk mengukur relevansi antara query dan dokumen. BM25 memperhitungkan frekuensi term, panjang dokumen, dan inverse document frequency. Dalam penelitian ini, BM25 digunakan untuk mengukur sejauh mana kata-kata dalam judul relevan dengan isi berita.

C. FastText

FastText merupakan metode representasi teks yang menghasilkan vektor embedding untuk setiap kata dengan mempertimbangkan *subword information*. Berbeda dengan Word2Vec yang memperlakukan setiap kata sebagai unit tunggal, FastText merepresentasikan kata sebagai kumpulan n-gram karakter, sehingga mampu menangani kata-kata yang jarang muncul atau tidak ada dalam *vocabulary*. Dalam penelitian ini, FastText dilatih dari awal menggunakan data kompetisi sesuai batasan yang berlaku.

D. LightGBM

LightGBM merupakan algoritma gradient boosting yang dikembangkan oleh Microsoft. Algoritma ini menggunakan teknik Gradient-based One-Side Sampling (GOSS) dan Exclusive Feature Bundling (EFB) untuk meningkatkan efisiensi pelatihan pada dataset besar. LightGBM mampu menangani fitur campuran antara numerik dan kategorikal, serta memiliki mekanisme penanganan kelas tidak seimbang melalui parameter class weight.

E. XGBoost

XGBoost (Extreme Gradient Boosting) merupakan algoritma ensemble berbasis gradient boosting yang dikenal memiliki performa tinggi pada berbagai tugas klasifikasi. XGBoost menggunakan regularisasi L1 dan L2 untuk mengurangi overfitting, serta mendukung penanganan missing values secara internal.


F. Optuna

Optuna merupakan *framework* optimasi hyperparameter yang menggunakan pendekatan Bayesian optimization dengan Tree-structured Parzen Estimator (TPE) [4]. Optuna

memungkinkan pencarian ruang hyperparameter secara efisien dan mendukung pruning *trial* yang tidak menjanjikan.

III. METODOLOGI


Bagian ini menjelaskan alur kerja penelitian secara terstruktur, mulai dari pemahaman dataset, prapemrosesan teks, rekayasa fitur, pemodelan, hingga evaluasi model. Gambar berikut menunjukkan diagram alur keseluruhan metodologi yang diterapkan.



Gambar 1 Diagram alur pipeline penelitian

A. Dataset


Dataset yang digunakan dalam penelitian ini berasal dari kompetisi Data Analysis Competition IFEST Unpad 2026 yang diselenggarakan di platform Kaggle. Dataset terdiri dari 14.394 data latih setelah proses pembersihan data duplikat dan 3.603 data uji. Setiap data terdiri dari pasangan judul berita (title) dan isi berita (content) dengan label biner, yaitu 1 (Sesuai) dan 0 (Tidak Sesuai). Distribusi kelas pada data latih menunjukkan ketidakseimbangan yang signifikan dengan proporsi 90,04% label Sesuai dan 9,96% label Tidak Sesuai.



Gambar 2 Distribusi kelas pada dataset latih

B. Eksplorasi Data

Tahap eksplorasi data dilakukan untuk memahami karakteristik dataset. Analisis menunjukkan bahwa rata-rata panjang judul berita adalah 10 kata dengan standar deviasi 1,97 kata, sedangkan rata-rata panjang isi berita adalah 310 kata dengan standar deviasi 169,58 kata. Panjang isi berita yang bervariasi signifikan ini menunjukkan perlunya fitur yang menangkap perbedaan panjang antara judul dan isi.



Gambar 3 Distribusi panjang kata pada judul dan isi berita

C. Prapemrosesan Teks


Prapemrosesan teks dilakukan untuk membersihkan dan menormalisasi teks sebelum ekstraksi fitur. Tahapan prapemrosesan meliputi: (1) konversi ke huruf kecil (*case folding*); (2) penghapusan URL dan tautan; (3) penghapusan karakter khusus dan tanda baca; serta (4) normalisasi spasi. Prapemrosesan dirancang untuk tidak terlalu agresif agar informasi penting dalam teks tetap pertahankan.

D. Rekayasa Fitur

Rekayasa fitur dalam penelitian ini dibagi menjadi dua kategori utama, yaitu fitur leksikal dan fitur semantik.

Fitur Leksikal: Fitur leksikal meliputi TF-IDF word-level dengan konfigurasi unigram dan bigram serta maksimal 10.000 fitur, BM25 yang menghitung skor relevansi antara judul dan isi berita, serta Jaccard Similarity yang mengukur tumpang tindih kata antara judul dan isi berita.

Fitur Semantik: Fitur semantik diperoleh dari representasi vektor FastText yang dilatih dari awal menggunakan data kompetisi dengan konfigurasi ukuran vektor 100 dimensi, window size 5, dan minimal count 2. Vektor embedding untuk setiap teks dihitung menggunakan rata-rata vektor seluruh kata dalam teks tersebut.



Gambar 4 Distribusi fitur kemiripan per label

E. Pemodelan

Pemodelan pada penelitian ini menggunakan *ensemble learning* yang menggabungkan algoritma LightGBM dan XGBoost. Kedua algoritma ini dipilih karena efisiensinya dalam memproses matriks *sparse* berdimensi tinggi serta ketangguhannya menangani data yang tidak seimbang (*imbalanced data*) [5]. Performa LightGBM kemudian dimaksimalkan melalui *Bayesian Optimization* menggunakan Optuna sebanyak 50 trials pada parameter *learning rate*, *max depth*, dan *class weight*. Pendekatan *tuning* ini

terbukti signifikan dalam meningkatkan performa model pada klasifikasi kelas tidak seimbang dibandingkan model *baseline* konvensional [5].

F. Evaluasi

Evaluasi model menggunakan skema *5-Fold Stratified Cross Validation* untuk menjaga proporsi kelas pada setiap lipatan (*fold*) pengujian. Metode *stratified* ini sejalan dengan praktik terbaik pada deteksi berita palsu untuk menjaga konsistensi distribusi data *unseen* dan meminimalisasi risiko *overfitting* [6]. Prediksi akhir (*Out-of-Fold* dan *Test*) dihasilkan melalui metode *blending* dengan rasio 50:50 antara probabilitas LightGBM dan XGBoost, karena integrasi *base learners* terbukti memberikan performa prediktif yang lebih superior pada dataset teks berita [6]. Keandalan model kemudian diukur menggunakan *Macro F1-Score* agar evaluasi tetap adil terhadap performa kelas minoritas dan tidak bias terhadap dominasi kelas mayoritas.

IV. HASIL DAN PEMBAHASAN

Dalam penelitian ini, *Macro F1-Score* digunakan sebagai metrik utama untuk mengevaluasi performa model. Metrik ini menghitung nilai F1-Score pada setiap kelas, kemudian mengambil rata-rata dari seluruh kelas. Karena penelitian ini menggunakan dua kelas, yaitu "Tidak Sesuai" dan "Sesuai", perhitungannya dapat dituliskan sebagai berikut:

Nilai *Macro F1-Score* berada pada rentang 0 hingga 1, dengan nilai yang lebih tinggi menunjukkan performa klasifikasi yang lebih baik pada kedua kelas. Pada penelitian ini, label 0 merepresentasikan kelas "Tidak Sesuai", sedangkan label 1 merepresentasikan kelas "Sesuai". Metrik ini digunakan karena jumlah data pada kedua kelas tidak seimbang, sehingga performa pada kelas minoritas tetap diperhitungkan dalam evaluasi. Model yang dikembangkan menggunakan pendekatan *ensemble learning* dengan menggabungkan dua algoritma *gradient boosting*, yaitu LightGBM dan XGBoost. Optimasi *hyperparameter* dilakukan menggunakan Optuna, sedangkan evaluasi internal dilakukan dengan *5-Fold Stratified Cross Validation* untuk menjaga proporsi kelas pada setiap *fold*. Pada pengujian eksternal, model memperoleh skor *Macro F1-Score* sebesar 0.58957. Sementara itu, hasil evaluasi internal menggunakan data *Out-of-Fold* (OOF) menunjukkan akurasi sebesar 82% dengan nilai *Macro F1-Score* sebesar 0.5723 pada *threshold* optimal 0.47.

Macro F1 @0.50	0.5689
Threshold optimal	0.47
Macro F1 @threshold opt	0.5723

Tabel 1 Hasil Threshold Tuning

Ketidakseimbangan jumlah data menyebabkan proses klasifikasi menjadi lebih sulit, terutama dalam menentukan batas keputusan antara kelas "Sesuai" dan "Tidak Sesuai". Pada model yang menggunakan pembobotan kelas untuk memberikan perhatian lebih terhadap kelas minoritas, distribusi probabilitas hasil prediksi dapat mengalami pergeseran sehingga batas *threshold* default 0.50 belum tentu menghasilkan performa terbaik. Oleh karena itu, dilakukan *Threshold Tuning* untuk mencari batas keputusan yang menghasilkan nilai *Macro F1-Score* terbaik. Hasil pengujian menunjukkan bahwa penurunan *threshold* dari 0.50 menjadi 0.47 memberikan peningkatan *Macro F1-Score* dari 0.5689 menjadi 0.5723. Dengan *threshold* 0.47, model menjadi lebih mudah menetapkan prediksi sebagai kelas 1 ("Sesuai"), sehingga dapat mengurangi kecenderungan model dalam memprediksi terlalu banyak sampel sebagai kelas 0 ("Tidak Sesuai") akibat pembobotan kelas. Meskipun peningkatannya relatif kecil, hasil tersebut menunjukkan bahwa penyesuaian batas keputusan dapat membantu memperoleh keseimbangan performa yang lebih baik antara kedua kelas.

Setelah diperoleh *threshold* optimal, performa model kemudian dianalisis pada masing-masing kelas untuk melihat bagaimana penyesuaian tersebut berpengaruh terhadap hasil klasifikasi. Hasil evaluasi menunjukkan adanya perbedaan performa yang cukup besar antara kelas mayoritas dan minoritas. Pada kelas mayoritas, yaitu "Sesuai", model memperoleh *Precision* sebesar 0.92, *Recall* sebesar 0.88, dan *F1-Score* sebesar 0.90. Sementara itu, pada kelas minoritas "Tidak Sesuai", nilai *Precision*, *Recall*, dan *F1-Score* masing-masing sebesar 0.21, 0.28, dan 0.24. Perbedaan tersebut berkaitan dengan jumlah data pada masing-masing kelas, yaitu 12.960 sampel untuk kelas "Sesuai" dan 1.434 sampel untuk kelas "Tidak Sesuai". Dengan jumlah sampel yang jauh lebih sedikit, kelas "Tidak Sesuai" masih lebih sulit dikenali oleh model dibandingkan kelas "Sesuai".

	Precision	Recall	F1-Score	Support
Tidak Sesuai (0)	0.21	0.28	0.24	1434
Sesuai (1)	0.92	0.88	0.90	12960

Tabel 2 Hasil Evaluasi Model Berdasarkan Kelas


Selain melihat performa pada masing-masing kelas, ringkasan evaluasi pada Tabel 2 menunjukkan pengaruh ketidakseimbangan data terhadap metrik agregat. Model memperoleh akurasi sebesar 82% dari total 14.394 sampel pada data *Out-of-Fold*. Namun, nilai *Weighted Average* menghasilkan *F1-Score* sebesar 0.84 karena perhitungannya mempertimbangkan jumlah sampel pada setiap kelas. Dengan jumlah kelas "Sesuai" yang jauh lebih besar, nilai tersebut lebih banyak dipengaruhi oleh performa model pada kelas mayoritas. Oleh karena itu, *Macro Average* digunakan sebagai metrik yang lebih sesuai untuk melihat keseimbangan performa antar kelas. Hasil evaluasi menunjukkan nilai *Macro Precision* sebesar 0.57, *Macro Recall* sebesar 0.58, dan *Macro F1-Score* sebesar

0.57. Nilai tersebut memberikan gambaran yang lebih seimbang mengenai kemampuan model dalam mengenali kedua kelas, terutama karena performa pada kelas minoritas masih relatif rendah.

	Precision	Recall	F1-Score	Support
Accuracy			0.82	14394
Macro avg	0.57	0.58	0.57	14394
Weighted avg	0.85	0.82	0.84	14394


Tabel 3 Ringkasan Metrik Evaluasi Model

Bias prediksi model ini divisualisasi secara jelas melalui *Confusion Matrix* dari pengujian *Out-of-Fold*, yang disajikan dalam bentuk nilai absolut dan persentase ternormalisasi. Berdasarkan matriks absolut, dari 1.434 sampel aktual kelas "Tidak Sesuai", sebanyak 408 sampel berhasil diprediksi dengan benar, sedangkan 1.026 sampel salah ditebak sebagai kelas "Sesuai" (*False Positives*). Sebaliknya, pada kelas "Sesuai", sebanyak 11.458 dari 12.960 sampel diprediksi secara akurat, dengan tingkat kesalahan klasifikasi (*False Negatives*) hanya sebesar 1.502 sampel.



Gambar 5 Confusion Matrix (Absolut) Hasil Evaluasi Out-Of-Fold

Distribusi performa ini terlihat lebih transparan melalui matriks ternormalisasi. Model terbukti hanya mampu mengenali 28,45% dari keseluruhan data aktual kelas minoritas ("Tidak Sesuai"), di mana 71,55% sisanya masih salah diklasifikasikan. Sebaliknya, pada kelas mayoritas ("Sesuai"), tingkat keberhasilan prediksi mencapai 88,41%. Tingginya angka salah tebak pada kelas minoritas ini memperjelas tantangan utama model dalam membedakan berita yang tidak relevan dengan judulnya, karena model sering kali "tertipu" dan menganggapnya valid akibat dominasi pola kelas mayoritas selama fase pelatihan.



Gambar 6 Confusion Matrix (Ternormalisasi) Hasil Evaluasi Out-Of-Fold

Performa tersebut juga dipengaruhi oleh penggunaan fitur yang dirancang untuk menangkap kemiripan antara judul dan isi berita. Jaccard Similarity dan BM25 membantu mengukur kemiripan berdasarkan kata yang digunakan, sedangkan FastText Cosine Similarity membantu menangkap kemiripan makna ketika terdapat perbedaan dalam penggunaan kata. Selain itu, perbaikan pada *pipeline preprocessing* dilakukan dengan memisahkan proses pemeriksaan data bersih (*checkpoint*) serta memastikan proses *fitting* TF-IDF dan BM25 hanya menggunakan data latih. Pengaturan tersebut membantu mencegah *data leakage* dan menjaga agar informasi dari data uji tidak masuk ke dalam proses pelatihan. Dengan kombinasi fitur tersebut dan perbaikan pada proses *preprocessing*, model dapat mengenali kesesuaian judul dan isi berita dengan lebih baik, meskipun hasil evaluasi menunjukkan bahwa ketidakseimbangan kelas masih menjadi faktor yang memengaruhi performa pada kelas "Tidak Sesuai".

KESIMPULAN DAN SARAN

Penelitian ini berhasil membangun sistem klasifikasi kesesuaian judul dan isi berita berbahasa Indonesia menggunakan ensemble LightGBM dan XGBoost dengan fitur TF-IDF, BM25, Jaccard Similarity, dan FastText. Model ensemble mencapai Macro F1-Score sebesar 0,58957 pada *leaderboard* Kaggle dan 0,5723 pada data Out-of-Fold dengan threshold optimal 0,47.

Berdasarkan hasil penelitian, beberapa kesimpulan dapat ditarik. Pertama, kombinasi fitur leksikal dan fitur semantik memberikan kontribusi positif terhadap kemampuan model dalam mengenali kesesuaian judul dan isi berita. Fitur BM25 dan Jaccard Similarity menangkap kemiripan berdasarkan kata, sedangkan FastText menangkap kemiripan makna. Kedua, ketidakseimbangan kelas yang signifikan (90:10) menjadi faktor utama yang membatasi performa model pada kelas minoritas, sebagaimana terlihat dari perbedaan F1-Score antara kelas Sesuai (0,90) dan kelas Tidak Sesuai (0,24). Ketiga, threshold tuning terbukti memberikan peningkatan meskipun relatif kecil, dari 0,5689 menjadi 0,5723.

Dari sisi penerapan, sistem ini paling realistis diposisikan sebagai alat bantu penyaringan awal (*pre-screening tool*) bagi redaksi media daring atau platform agregator berita, bukan sebagai pengganti keputusan

editorial. Mengingat performa model pada kelas minoritas "Tidak Sesuai" masih rendah (F1-Score 0,24), sistem berisiko melewatkan sebagian besar berita clickbait jika digunakan sebagai filter otomatis penuh (*recall* kelas minoritas hanya 0,28). Oleh karena itu, rekomendasi penerapan yang lebih aplikatif adalah menjadikan output model sebagai skor prioritas: berita dengan probabilitas "Tidak Sesuai" di atas ambang tertentu diarahkan untuk ditinjau manual oleh tim editor sebelum dipublikasikan atau didistribusikan lebih luas, sehingga beban verifikasi manual terpusat pada subset berita berisiko tinggi, bukan pada seluruh artikel. Pendekatan *human-in-the-loop* ini juga memungkinkan umpan balik editor terhadap prediksi yang salah dikumpulkan sebagai data latih tambahan, yang secara bertahap dapat memperkuat kemampuan model dalam mengenali pola clickbait yang terus berkembang mengikuti tren media digital di Indonesia.

Saran untuk penelitian selanjutnya meliputi: (1) penggunaan teknik *resampling* seperti SMOTE atau *oversampling* untuk mengatasi ketidakseimbangan kelas; (2) eksplorasi data eksternal berita Indonesia untuk meningkatkan jumlah sampel kelas minoritas; (3) penggunaan arsitektur *deep learning* yang dilatih dari awal untuk menangkap pola sekuensial; serta (4) analisis lebih mendalam terhadap kasus-kasus sulit yang gagal diklasifikasikan oleh model.

REFERENCES

- [1] S. Kurniawan, A. S. Pramayoga, Y. F. Ashari, and M. A. Amrustian, "Development and Evaluation of an IndoBERT-Based NLP Model for Automated Clickbait Detection," *Advance Sustainable Science, Engineering and Technology*, vol. 8, no. 1, Nov. 2026, doi: 10.26877/asset.v8i1.2637.
- [2] O. Solihin, R. Widyaningrum, F. Haryati, Y. Mogot, Z. Fachrul Nurhadi, and E. Agus Waluyo, "TINJAUAN TENTANG CLICKBAIT MEDIA," *Jurnal Komunikasi dan Media*, Aug. 2022, doi: 10.33884/comm.v7i1.
- [3] A. Brasoveanu, M. Moodie, and R. Agrawal, "Textual evidence for the perfunctoriness of independent medical reviews," in *CEUR Workshop Proceedings*, CEUR-WS, 2020, pp. 1–9. doi: 10.1145/nnnnnnnn.nnnnnnnn.
- [4] S. Watanabe, "Tree-Structured Parzen Estimator: Understanding Its Algorithm Components and Their Roles for Better Empirical Performance," May 2026, [Online]. Available: <http://arxiv.org/abs/2304.11127>
- [5] P. Zhang, Y. Jia, and Y. Shang, "Research and application of XGBoost in imbalanced data," *Int. J. Distrib. Sens. Netw.*, vol. 18, no. 6, Jun. 2022, doi: 10.1177/15501329221106935.
- [6] I. Salah, K. Jouini, and O. Korbaa, "On the use of text augmentation for stance and fake news detection," *Journal of Information and Telecommunication*, vol. 7, no. 3, pp. 359–375, 2023, doi: 10.1080/24751839.2023.2198820.